



SOUVERÄNE ON-PREMISE-KI · VON TWENTY5AI

TECHNISCHES WHITEPAPER

Ihre KI. Ihre Hardware. Kein Byte verlässt das Haus.

Wie Quinta aus eigener Hardware einen privaten, OpenAI-kompatiblen KI-Dienst macht — mit Enterprise-Verwaltung, lückenlosem Audit-Trail und ohne Datenabfluss.

GDPR-KONFORM

EU-AI-ACT-READY

100 % EUROPÄISCH

OPENAI-KOMPATIBLE API

Souveränität kostet keine Leistung — sie liefert sie.

Quinta ist keine weitere Inferenz-Engine, sondern die komplette Betriebsschicht, die ein reguliertes Unternehmen braucht, um KI produktiv zu betreiben: Zugriffskontrolle, Multi-GPU-Orchestrierung, Governance und ein lückenloser Prüfpfad — vollständig auf der eigenen Hardware.

- OpenAI-kompatible API: bestehende Anwendungen migrieren, indem sie `base_url` und API-Key ändern — sonst nichts.
- Läuft on-premise, von der Workstation bis zur KI-Appliance; skaliert horizontal über selbstregistrierende GPU-Knoten.
- Zwei Inferenz-Motoren eingebaut: ein leichtgewichtiger Modell-Runner für den Einstieg, vLLM für Hochleistung und den gesamten HuggingFace-Katalog.
- Enterprise-Verwaltung: Dashboard, RBAC, vier Login-Methoden, Multi-Organisation, Audit-Trail, Fine-Tuning und MCP.
- Kein Datentransfer, kein externer Auftragsverarbeiter für die Inferenz — die Grundlage für DSGVO, EU AI Act und NIS2.

Cloud-KI heißt: fremde Infrastruktur, fremde Regeln.

Daten verlassen Europa

Sensibelste Daten gehen an US-Cloud-APIs — ohne Audit-Trail, mit GDPR-, EU-AI-Act- und NIS2-Risiko.

Kosten ohne Obergrenze

Token-Abrechnung macht Budgets unkalkulierbar. Jeder neue Anwendungsfall verteuert den Betrieb.

Abhängigkeit von Anbietern

Modelle, Preise und Verfügbarkeit bestimmt ein Dritter. Ein API-Wechsel bedeutet Umbau statt Umzug.

Kein Nachweis

Der Prüfpfad endet an der Systemgrenze des Anbieters — genau dort, wo Regulierung ihn verlangt.

Kein Model-Runner. Die komplette Betriebsschicht.

Jede Anfrage nimmt denselben Weg: durch das Gateway (Pfortner), zum Daemon auf dem GPU-Rechner, in das Modell — verbunden über eine zentrale Registry. Jeder weitere Rechner mit dem Quinta-Daemon wird automatisch Teil der Plattform.



Zwei Inferenz-Motoren

vLLM — Hochleistung für Produktion, ganzer HuggingFace-Katalog (Llama, Mistral, Qwen, Gemma, DeepSeek). Vollautomatischer Lebenszyklus: Download → Warmup → ready.

Leichter Modell-Runner — einfacher Einstieg, von der Workstation bis zur DGX-Spark-Klasse. GPU-Erkennung für NVIDIA, AMD und Intel, automatisches Routing.

Migration in zwei Zeilen

```
client = OpenAI(  
    base_url="https://quinta.intern/v1",  
    api_key="qnt-prod-...",  
)
```

Chat, Embeddings, Rerank, Audio-Transkription und die Responses-API — kein Umprogrammieren, kein neues SDK.

04 — Leistung

Gleiche Engine. Ein anderes Verhalten am Limit.

18×

höhere Erfolgsquote unter
Extremlast (bounded admission)

~56 ms

zusätzliche Erst-Latenz — Token-
Rate pro Nutzer identisch

512

gleichzeitige Anfragen im Test

Benchmark der zugrunde liegenden Engine, gemessen auf NVIDIA DGX Spark (128 GB): 31.200 Requests, bis 512 gleichzeitige Anfragen, Quinta-Gateway gegen vLLM pur. Das Gateway dosiert Anfragen und fängt Fehler ab, bevor Nutzer sie sehen — bei identischer Inferenz.

05 — Enterprise-Funktionen

Gebaut für IT-Leitung, nicht nur für Entwickler.

Deployments per Klick

Modelle ausrollen, skalieren und zurückziehen —
ohne Terminal.

API-Key-Verwaltung

Keys je Team und Anwendung, jederzeit
widerrufbar.

Multi-Organisation (RBAC)

Mandantenfähig, Rollen & Rechte, Team-
Einladungen.

4 Login-Methoden

Passwort, 2-Faktor (TOTP), Passkeys,
SSO/SAML (Entra ID, Okta).

Verbrauch & Metriken

Tracking je Einheit plus Prometheus-Metriken.

Lückenloser Audit-Trail

Jeder Zugriff, jede Änderung nachvollziehbar —
revisionssicher.

Fine-Tuning

Eigene Modelle anpassen, direkt aus der
Oberfläche.

MCP-Schnittstelle

KI-Assistenten verwalten die Infrastruktur selbst.

Regulatorik ist kein Anhang. Sie ist der Grund.

GDPR / DSGVO

Verarbeitung bleibt im Haus: kein Drittstaaten-Transfer, kein Auftragsverarbeiter für die Inferenz.

EU AI Act

Volle Kontrolle über Modelle und Versionen; Audit-Trail als Dokumentationsgrundlage.

NIS2

Betrieb in der eigenen Sicherheitszone: SSO/RBAC, nachvollziehbare Administration.

Kein AVV für die Inferenz

Ohne externen Auftragsverarbeiter entfällt das Übermittlungs- und AVV-Risiko der Cloud-KI.

„Kein Byte verlässt das Haus“ heißt datenschutzrechtlich: kein Transfer, kein fremder Auftragsverarbeiter, kein Zugriff nach fremdem Recht.

07 — Einführung

Drei Schritte bis zum eigenen KI-Dienst.

- 01 · Planen** 30-Minuten-Gespräch: Anwendungsfälle, Hardware, Compliance-Rahmen. Danach steht der Deployment-Plan.
- 02 · Deployen** Daemon auf die GPU-Rechner, Gateway und Dashboard dazu — Knoten registrieren sich selbst, Modelle starten automatisch. Stunden, nicht Monate.
- 03 · Betreiben** Deployments per Klick, API-Keys, Verbrauch pro Einheit, Prometheus-Metriken und lückenloser Audit-Trail im Dashboard.

08 — Editionen

Business und Enterprise.

- Business** Für den produktiven Einsatz — mehrere Rechenknoten, RBAC, API-Keys, Modell-Management. Preis auf Anfrage (Lizenz je Standort).
- Enterprise** Zusätzlich Multi-Standort, SSO/SAML, 2FA & Passkeys, Audit-Trail, Fine-Tuning-UI & MCP, fester Ansprechpartner. Individueller Vertrag & SLA.

quinta.

Holen Sie Ihre KI nach Hause. Demo buchen (30 Min.).

hello@twenty5ai.com

quinta.twenty5ai.com

Benchmark-Zahlen beziehen sich auf die Messung der zugrunde liegenden Engine (Quinta-Gateway vs. vLLM pur, NVIDIA DGX Spark 128 GB) und werden unverändert wiedergegeben. Aussagen zu Compliance beschreiben die Architektur, keine Zertifizierungen. Der Inferenz-Motor basiert auf Open-Source-Technologie (Apache 2.0); die Verwaltungsebene ist eine Eigenentwicklung von twenty5ai. Dieses Dokument ist keine Rechtsberatung.